DOCUMENTO OFICIAL DE ENTREGA

Reporte técnico del proyecto

Análisis del mercado de motos y vehículos ligeros en La Habana: recolección, procesamiento, evidencia cuantitativa y cualitativa.

Proyecto: Mercado de Motos en Cuba
Asignatura: Introducción a la Ciencia de los Datos
Alcance: oferta publicada en La Habana y entrevistas a compradores, talleres e importadoras
Fecha del documento: 5 de noviembre de 2026

6.101 anuncios analizados | 30 entrevistas | 4 categorías de vehículos | Validación reproducible

Versión	1.0 — Entrega final
Fuente cuantitativa	Anuncios públicos de Revolico (La Habana), 10–26 de octubre de 2026
Fuente cualitativa	25 compradores, 4 talleres y 1 importadora (transcripción Vosk y entrevistas en texto)
Repositorio	`Mercado-de-Motos`

Documento técnico preparado para evaluación académica. Las cifras provienen de los archivos del repositorio y son reproducibles con los comandos del apartado 10.

Contenido

1. Resumen ejecutivo
2. Introducción, problema y objetivos
3. Alcance y fuentes de datos
4. Arquitectura y organización del proyecto
5. Metodología cuantitativa
6. Metodología cualitativa
7. Resultados cuantitativos
8. Resultados cualitativos
9. Validación y control de calidad
10. Limitaciones metodológicas
11. Reproducibilidad
12. Conclusiones
13. Anexos

Ficha del documento

Elemento	Descripción
Tipo	Reporte técnico detallado del proyecto
Unidad de análisis	Anuncios de vehículos ligeros y entrevistas a actores del mercado
Cobertura geográfica	La Habana, Cuba
Periodo del dataset	2026-10-10 a 2026-10-26
Periodo de entrevistas	2026-10-23 a 2026-11-05
Herramientas	Python 3, pandas, Vosk, scripts de scraping, validadores y pytest

1. Resumen ejecutivo

El proyecto analiza el mercado de motos y vehículos ligeros en La Habana combinando dos fuentes primarias: **6.101 anuncios** publicados en Revolico entre el 10 y el 26 de octubre de 2026 y **30 entrevistas** a compradores, talleres e importadoras. El objetivo es describir la composición de la oferta, los precios, las marcas y las prácticas del mercado, así como interpretar las decisiones de compra y uso.

6.101	78,3 %	30
ANUNCIOS DEPURADOS	OFERTA ELÉCTRICA (MOTOS + BICIS)	ENTREVISTAS INTEGRADAS

Hallazgos principales

- **La oferta está dominada por la movilidad eléctrica.** Las bicicletas eléctricas (2.576; 42,2 %) y las motos eléctricas (2.201; 36,1 %) concentran el 78,3 % de los anuncios; la combustión representa el 18,0 % (1.099) y los patinetes el 3,7 % (225).
- **Los precios medianos son 2.250 USD en combustión y 2.050 USD en eléctricas.** La bicicleta eléctrica es la opción más barata (mediana 1.150 USD) y el patinete la más homogénea (750 USD).
- **El mercado se cotiza en dólares:** 6.064 de 6.101 anuncios (99,4 %) están en USD.
- **Topmaq lidera la oferta** (506 anuncios), seguida de JMD (227) y Mountain (187); casi la mitad de los anuncios (47,7 %) no declara marca.
- **Las entrevistas muestran un uso laboral intensivo** y problemas recurrentes de autonomía, batería, repuestos y apagones. Los canales observados son Revolico, Facebook, conocidos e importación.

> **Lectura correcta de los resultados:** el dataset describe la *oferta publicada*, no las ventas efectivas. Las entrevistas son una muestra pequeña y no probabilística. Por eso el informe distingue entre datos cuantitativos, percepciones cualitativas y preguntas que quedan pendientes.

2. Introducción, problema y objetivos

2.1 Contexto

La movilidad urbana en La Habana enfrenta restricciones de transporte, combustible y acceso a repuestos. En ese contexto, las motos, bicicletas eléctricas y patinetes se consolidaron como alternativas de bajo consumo y alta flexibilidad. Sin embargo, gran parte de esa actividad ocurre en un mercado informal o semiformal, con precios volátiles y poca información pública sistematizada.

2.2 Problema de investigación

No existe una caracterización reproducible de la oferta de vehículos ligeros en La Habana que permita responder con evidencia: qué se ofrece, a qué precios, con qué marcas, con qué demanda aparente y cómo viven ese mercado quienes compran, venden y reparan.

2.3 Objetivo general

Analizar la oferta de motos de combustión, motos eléctricas, bicicletas eléctricas y patinetes anunciados en La Habana, mediante técnicas de recolección, procesamiento y análisis de datos, para identificar patrones de precios, composición del mercado y tendencias relevantes.

2.4 Objetivos específicos

1. Recolectar y depurar anuncios públicos de Revolico de las cuatro categorías oficiales.
2. Describir la composición de la oferta y su distribución de precios.
3. Identificar marcas, rangos de precio y señales de demanda (vistas).
4. Complementar la lectura cuantitativa con evidencia cualitativa de compradores, talleres e importadoras.
5. Documentar el proceso de forma reproducible y auditable.

2.5 Preguntas de investigación

- ¿Cómo está compuesto el mercado de vehículos ligeros anunciados en La Habana?
- ¿Qué diferencias existen entre los precios de las motos de combustión y las eléctricas?
- ¿Qué marcas aparecen con mayor frecuencia?
- ¿Qué categorías tienen mayor presencia en la oferta observada?
- ¿Qué tendencias pueden identificarse a partir de los anuncios?
- ¿Cómo influyen disponibilidad, mantenimiento y repuestos en las preferencias de los usuarios?

3. Alcance y fuentes de datos

3.1 Fuente cuantitativa

Elemento	Detalle
Sitio	Revolico (anuncios clasificados)
Ciudad	La Habana, Cuba
Periodo	2026-10-10 a 2026-10-26
Registros brutos	6.344 (3 archivos: 6.246 + 46 + 52)
Anuncios depurados	6.101
Categorías	Motos de combustión, motos eléctricas, bicicletas eléctricas y patinetes
Campos principales	título, descripción, categoría, precio, moneda, precio en USD, fecha, vistas, ubicación, marca, modelo, URL

3.2 Fuente cualitativa

Tipo	Cantidad	Formato
Compradores	25	23 con audio transcrito con Vosk; 2 en texto
Talleres	4	Audio transcrito con Vosk
Importadoras	1	Audio transcrito con Vosk (Solimport)
Total	**30**	Entrevistas semiestructuradas

3.3 Consideraciones éticas

- No se publican nombres, teléfonos ni direcciones.
- Los registros usan identificadores: `COMPRADOR_001`, `TALLER_001`, `IMPORTADORA_001`.
- Se registra solo lo que la persona declara; lo no inteligible queda como `null` y en `preguntas_pendientes`.
- El consentimiento se registra explícitamente cuando existe audio.

4. Arquitectura y organización del proyecto

El repositorio separa datos crudos, datos procesados, documentación, reportes y código. Esa separación permite auditar cada etapa y regenerar los resultados sin sobrescribir la evidencia original.

```
Mercado-de-Motos/
├── data/
│   ├── raw/            anuncios crudos y audios/transcripciones (audios ignorados por Git)
│   └── processed/      anuncios_limpios.csv/json y manifiesto
├── docs/
│   ├── entrevistas/    JSON normalizados, esquema, guía y análisis
│   ├── entregables/    HANDOFF, resumen ejecutivo, reporte técnico
│   ├── images/         evidencia fotográfica de campo
│   ├── metodologia/    decisiones de arquitectura
│   └── journal.md      bitácora cronológica
├── reports/
│   ├── metricas/       resumen_mercado.json y csv
│   └── graficos/       5 gráficos del análisis
├── src/
│   ├── scraping/revolico/   recolección
│   ├── analisis/            ETL y generación de reportes
│   └── cualitativo/         transcripción y captura de entrevistas
├── tests/              pruebas del dataset
├── codigo/             copia de los scripts de análisis cualitativo
└── notebooks/          exploración
```

4.1 Tecnologías

- **Python 3** y **pandas** para ETL y métricas.
- **Vosk** (`vosk-model-small-es-0.42`) para transcripción local de audios.
- **pytest** para pruebas y **scripts propios** para validación estructural de entrevistas.
- **Git/GitHub** para control de versiones y trazabilidad.

4.2 Flujo general

1. Recolección automatizada de anuncios de Revolico.
2. Limpieza, normalización y clasificación en las cuatro categorías.
3. Deduplicación y generación del dataset procesado.
4. Cálculo de métricas (precios, demanda, marcas) y gráficos.
5. Recolección y transcripción de entrevistas.
6. Normalización a JSON y análisis cualitativo.
7. Validación, documentación y publicación del reporte.

5. Metodología cuantitativa

5.1 Recolección

La recolección se hizo con un scraper propio sobre Revolico, con paginación y almacenamiento en bruto. Se conservaron tres archivos fuente con un total de **6.344 registros**, identificados por hash SHA256 en el manifiesto del proyecto. La depuración redujo el conjunto a **6.101 anuncios**.

5.2 Normalización y variables

Variable	Tratamiento
`precio` / `moneda`	Se conserva el valor original; los precios en CUP no entran en las estadísticas en USD.
`precio_usd`	Precio comparable en USD; 239 anuncios quedaron sin precio válido.
`categoria_clave`	Clasificación en cuatro categorías oficiales.
`marca_mostrar`	Marca normalizada; 2.910 anuncios quedaron como “sin marca”.
`fecha_dia`	Fecha del anuncio; permite cortes diarios.
`vistas`	Indicador indirecto de demanda/interés.

5.3 Clasificación

Los anuncios se agruparon en: **motos de combustión**, **motos eléctricas**, **bicicletas eléctricas** (incluye bicimotos) y **patinetes**. La categoría de bicicletas eléctricas se conserva porque compite directamente con las motos eléctricas en precio y uso.

5.4 Deduplicación

Se aplicó deduplicación por identificador del anuncio y por repetición exacta de contenido. El manifiesto conserva los hashes de los archivos fuente para auditar qué entró al dataset final.

5.5 Métricas

Para cada categoría se calcularon: número de anuncios, mínimo, P25, mediana, P75, máximo, promedio, desviación estándar, vistas totales, vistas medianas y vistas promedio. Las medianas se usan como medida central porque resisten mejor los valores extremos.

6. Metodología cualitativa

6.1 Instrumento

Se aplicó una entrevista semiestructurada de 10 a 15 minutos, organizada en bloques: perfil, compra, uso y gastos, repuestos y servicio, precios y mercado, y satisfacción. El instrumento está documentado en `docs/entrevistas/guia_entrevista.md` y su versión legible por máquina en `cuestionario.json` / `cuestionario.csv`.

6.2 Transcripción

Los audios se transcribieron localmente con **Vosk** (`vosk-model-small-es-0.42`). Se intentó primero `faster-whisper` / `ctranslate2`, pero el entorno produjo un fallo de acceso a memoria; por eso se adoptó Vosk. La transcripción se marca como automática y no se corrige el habla.

6.3 Normalización

Cada entrevista se convirtió a un JSON con bloques estables: `perfil`, `compra`, `uso`, `repuestos`, `opiniones_mercado` y `satisfaccion`. Se registran solo respuestas explícitas; lo demás queda en `null` y en `preguntas_pendientes`.

6.4 Muestra final

Grupo	Cantidad	Observación
Compradores	25	`COMPRADOR_001` a `COMPRADOR_025`
Talleres	4	`TALLER_001` a `TALLER_004`; identidad por confirmar
Importadoras	1	`IMPORTADORA_001` (Solimport)

6.5 Duplicados y control

Se detectaron y descartaron audios duplicados, entre ellos un archivo de la carpeta 19 idéntico a `COMPRADOR_007`. Las entrevistas en texto (`COMPRADOR_003` y `COMPRADOR_025`) se registran sin audio y con `transcripcion_automatica: false`.

7. Resultados cuantitativos

7.1 Composición de la oferta

Categoría	Anuncios	% del total	Precio mediano (USD)	P25	P75	Vistas medianas
Bicicletas eléctricas	2.576	42,2 %	1.150	670	1.650	7
Motos eléctricas	2.201	36,1 %	2.050	1.300	2.630	6
Motos de combustión	1.099	18,0 %	2.250	1.900	2.592,5	8
Patinetes	225	3,7 %	750	730	800	5

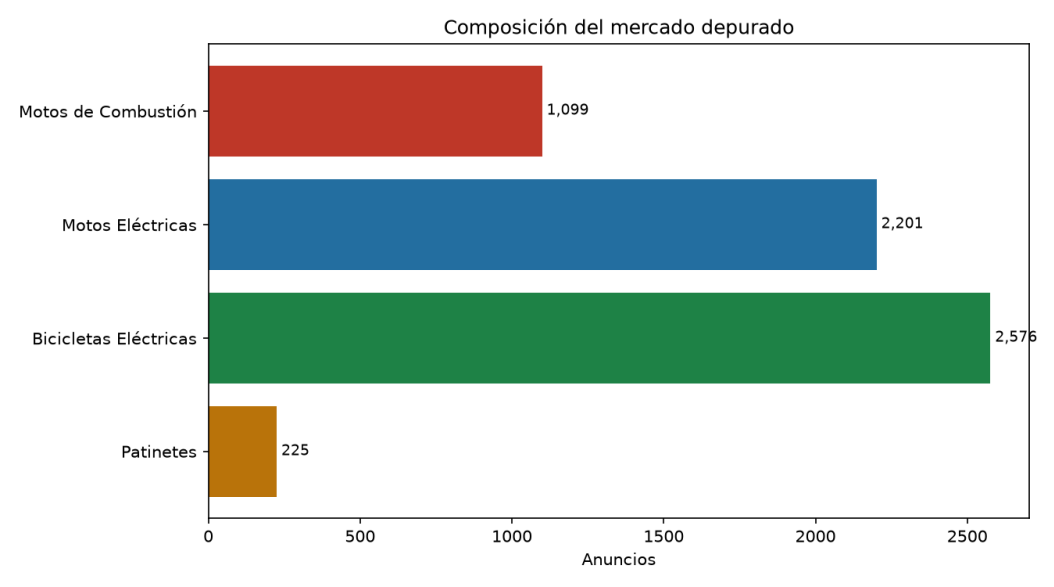


Figura 1. Composición de la oferta por categoría.

7.2 Precios

Categoría	n con precio	Mín.	Mediana	Máx.	Promedio	Desv.
Motos de combustión	990	111	2.250	4.500	2.209,87	595,03
Motos eléctricas	1.996	100	2.050	6.600	1.979,01	949,76
Bicicletas eléctricas	2.422	100	1.150	2.600	1.183,53	528,16
Patinetes	198	420	750	1.100	764,89	81,06

La **eléctrica** tiene la mayor dispersión: precios desde 100 hasta 6.600 USD. La **combustión** se concentra en un rango más estrecho (1.900–2.592 USD en el 50 % central). La **bicicleta eléctrica** es la puerta de entrada más económica y el **patinete** el mercado más homogéneo.

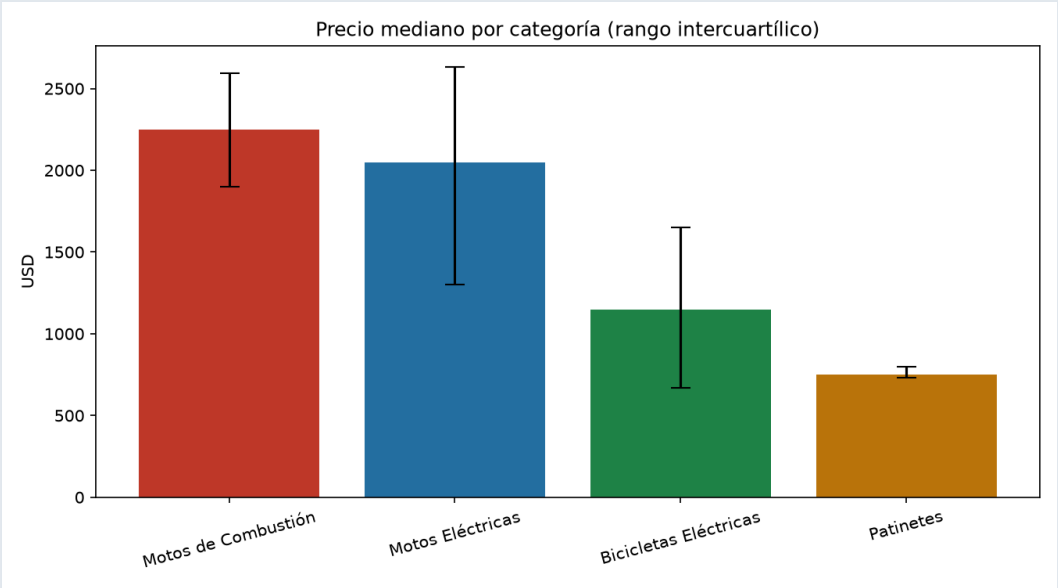


Figura 2. Distribución de precios por categoría.

7.3 Demanda aparente

Categoría	Vistas totales	Vistas medianas	Vistas promedio
Motos de combustión	68.569	8	62,4
Bicicletas eléctricas	67.828	7	26,3
Motos eléctricas	33.454	6	15,2
Patinetes	1.904	5	8,5

Las medianas son similares, pero los promedios de combustión son mucho más altos, lo que indica anuncios con picos de interés. Las vistas son un indicador *indirecto*: miden atención, no ventas.

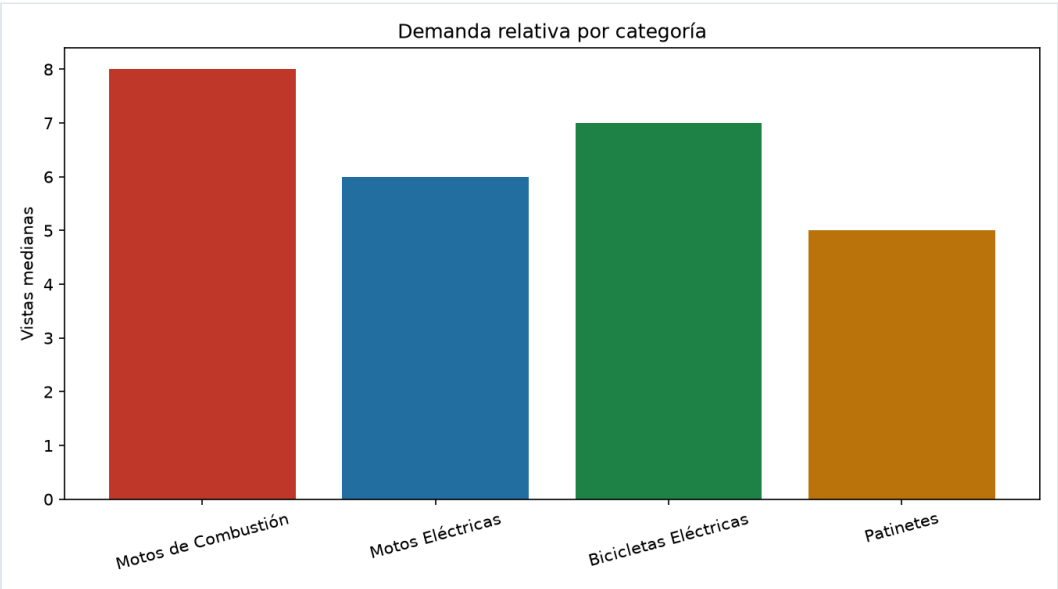


Figura 3. Vistas por categoría.

7.4 Marcas

Marca	Anuncios	Mediana USD
Topmaq	506	2.365
JMD	227	1.500
Mountain	187	2.280
Vedca	173	1.600
Challenger	170	820
Yoazaky	165	1.835
Bucatti	131	2.450
Motico	129	850
Mishozuki	95	1.900
Halcón	87	—

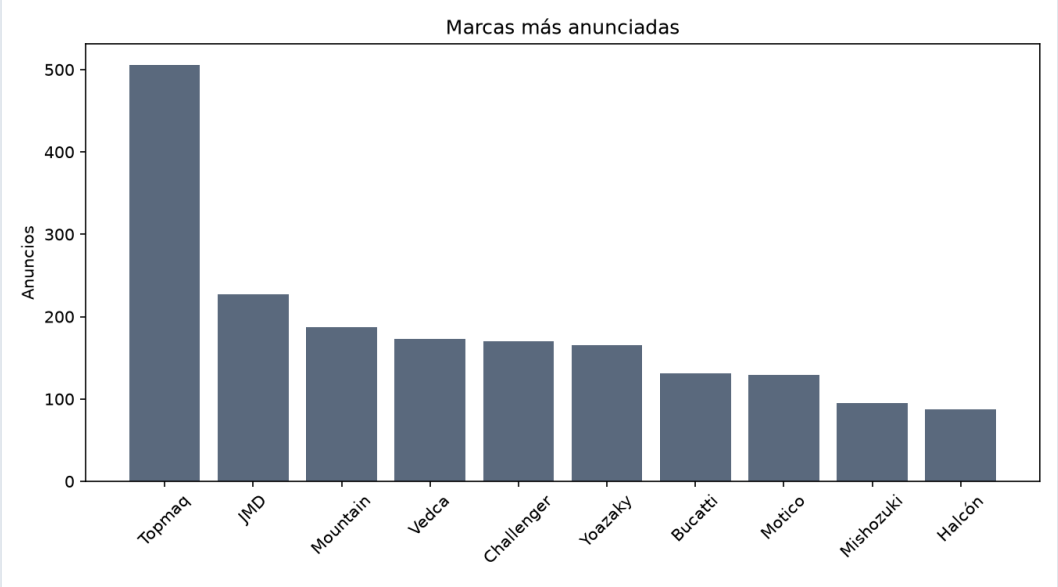


Figura 4. Marcas con más anuncios.

> **Advertencia:** 2.910 anuncios (47,7 %) no declaran marca. El ranking mide presencia en la oferta publicada, no ventas ni participación de mercado.

7.5 Cortes y evolución

Corte	Anuncios	Combustión	Eléctricas	Bicis eléctricas	Patinetes
2026-10-22	30	7	5	14	4
2026-10-26	30	9	3	17	1

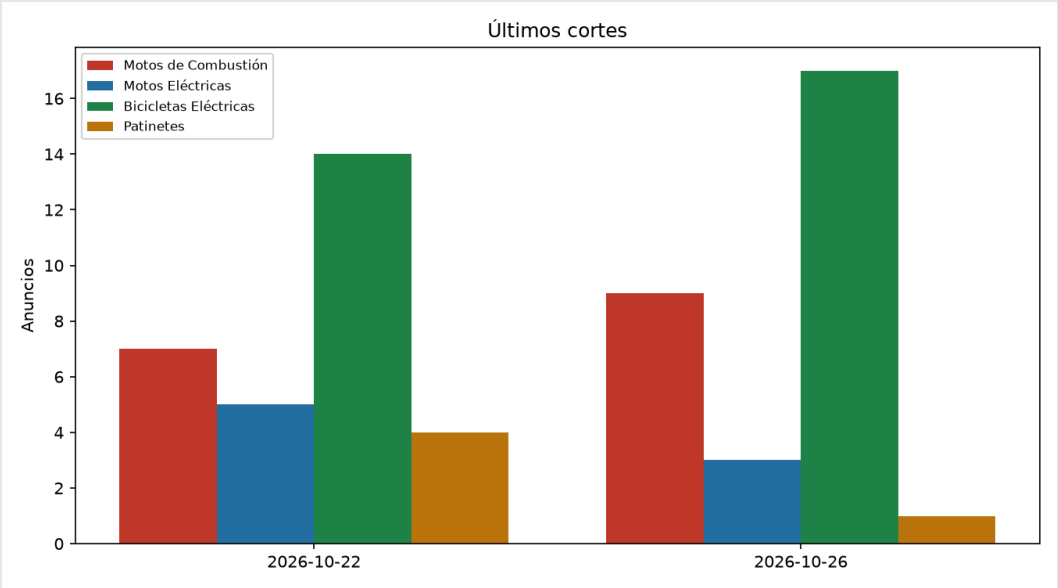


Figura 5. Cortes comparables de 30 anuncios.

8. Resultados cualitativos

Las 30 entrevistas permiten interpretar los números: quién compra, para qué usa la moto, qué le duele y qué valora. Los temas se repiten con suficiente frecuencia como para orientar conclusiones, aunque no para generalizar.

8.1 Uso laboral

El uso de trabajo es el patrón dominante: 8 compradores declaran uso exclusivo de trabajo, 3 mixto (trabajo/recados) y 2 mensajería/reparto; solo 2 declaran uso personal. Los talleres también describen un uso laboral intensivo. La moto aparece como herramienta de ingreso, no solo como transporte.

8.2 Autonomía y batería

Las percepciones son divergentes: un comprador reporta que la autonomía disminuyó con el tiempo (`COMPRADOR_020`), otro que aumentó (`COMPRADOR_023`), otro que la anunciada era real pero se degradó (`COMPRADOR_025`) y un taller señala que varía según peso, velocidad y lomas (`TALLER_004`). El reemplazo de batería se percibe como el costo grande de la eléctrica; una batería de mayor capacidad se compró por 800 USD.

8.3 Apagones y carga

Los apagones condicionan el uso: `COMPRADOR_025` afirma que a veces no puede usar la moto; `COMPRADOR_023` dice que lo afectan mucho. La carga suele hacerse de noche y, en algunos casos, hasta dos veces al día. Es el principal costo no monetario de la eléctrica en La Habana.

8.4 Repuestos y mantenimiento

En combustión aparecen problemas de piezas, aceite y neumático; en eléctrica, puño de acelerar, plásticos y estética. Conseguir repuestos es una dificultad recurrente, pero el proyecto no alcanza a construir un ranking de piezas ni una serie de precios de repuestos.

8.5 Canales y precios

Los canales observados son **Revolico**, **Facebook**, **conocidos** e **importación** (un caso desde Panamá). Un comprador pagó 1.000 USD por una eléctrica usada; otro ronda los 2.000 USD (moneda por confirmar). La importadora describe la formación del precio como proveedor + transporte + nacionalización + aranceles + impuesto de ventas + margen.

> *"Hoy elegiría una moto de combustión, aun cuando el precio de la gasolina suba; es más práctico y seguro para resolver las cosas en el día." — COMPRADOR_025*

> *"El avance se inclina hacia los equipos eléctricos; la compra de combustión se mantiene por la situación del combustible." — IMPORTADORA_001*

9. Validación y control de calidad

Comprobación	Herramienta	Resultado
Integridad del dataset	`src/verificar_datos.py`	Válido: 6.101 anuncios
Pruebas automatizadas	`pytest -q`	2 pruebas aprobadas
Estructura de entrevistas	`validar_entrevistas.py`	30 entrevistas, 38 hashes de audio únicos
Compilación	`py_compile`	Sin errores
Auditoría de fuentes	`manifiesto.json`	3 archivos fuente con SHA256

> **Errores conocidos y documentados del validador:** `COMPRADOR_001` y `COMPRADOR_002` (texto original multiparte), `COMPRADOR_003` (entrevista en texto) e `IMPORTADORA_001` (esquema propio, sin bloques de comprador). No afectan las cifras ni la validez del dataset; están registrados para no confundirlos con fallos nuevos.

9.1 Trazabilidad

- Cada audio conserva su SHA256 y su duración.
- Cada entrevista normalizada apunta a su transcripción en `data/raw/entrevistas/`.
- Los anuncios conservan URL y fecha, lo que permite volver a la fuente.
- El historial de cambios está en Git y en `docs/journal.md`.

10. Limitaciones metodológicas

1. **El dataset mide oferta, no ventas.** Un anuncio publicado no implica una transacción.
2. **Ventana corta:** 17 días (10–26 de octubre de 2026). No permite medir crecimiento ni estacionalidad.
3. **Una sola plataforma:** Revolico. Facebook, Telegram, importadoras y conocidos solo están cubiertos cualitativamente.
4. **Sin municipio:** la ubicación figura como "La Habana", así que no se puede analizar la variación por zona.
5. **Marca incompleta:** 47,7 % de los anuncios no declara marca.
6. **Muestra cualitativa pequeña y no probabilística:** 30 entrevistas, con audios ruidosos y respuestas incompletas.
7. **Identidad de talleres por confirmar:** la asignación proviene de la carpeta de origen.
8. **Datos sensibles:** precios, aranceles y remesas requieren confirmación adicional.

11. Reproducibilidad

El proyecto se reproduce con Python 3 y las dependencias declaradas en `requirements.txt`. Los comandos principales son:

```
# 1) Verificar el dataset
python src/verificar_datos.py

# 2) Regenerar métricas y reportes
python src/analisis/etl_mercado.py
python src/analisis/generar_reporte.py

# 3) Transcribir un audio con Vosk
python src/cualitativo/transcribir_vosk.py "ruta/audio.ogg" --modelo "modelos/vosk-model-small-es-0.42" --
salida "data/raw/entrevistas/ID.md"

# 4) Normalizar y validar entrevistas
python codigo/analisis_entrevistas/normalizar_lote.py
python codigo/analisis_entrevistas/validar_entrevistas.py

# 5) Pruebas
pytest -q
```

12. Conclusiones

1. La oferta de vehículos ligeros en La Habana está **mayoritariamente electrificada**: 78,3 % entre motos y bicicletas eléctricas.
2. Los precios medianos colocan a la **combustión (2.250 USD)** por encima de la **eléctrica (2.050 USD)**, pero la eléctrica tiene mucha más dispersión.
3. **Topmaq** lidera la presencia en la oferta, aunque la mitad de los anuncios no declara marca.
4. Las entrevistas explican el atractivo de la eléctrica (carga nocturna, bajo costo por energía) y sus límites (batería, autonomía, apagones, repuestos).
5. El proyecto deja una base reproducible y auditables, con brechas claras: zona, serie temporal, condición nueva/usada, aranceles y repuestos.

Anexos

A. Entrevistas integradas

Grupo	IDs	Cantidad	Formato
Compradores	`COMPRADOR_001` – `COMPRADOR_025`	25	23 audio + 2 texto
Talleres	`TALLER_001` – `TALLER_004`	4	Audio
Importadora	`IMPORTADORA_001`	1	Audio

B. Archivos clave

Ruta	Contenido
`data/processed/anuncios_limpios.csv`	Dataset de 6.101 anuncios
`reports/metricas/resumen_mercado.json`	Métricas por categoría y marcas
`reports/graficos/`	5 gráficos del análisis
`docs/entrevistas/compradores.json`	25 entrevistas normalizadas
`docs/entrevistas/talleres.json`	4 entrevistas de talleres
`docs/entrevistas/importadoras.json`	1 entrevista de importadora
`docs/entrevistas/analisis_lote_2026-11-05.md`	Análisis cualitativo transversal
`docs/entregables/reporte_tecnico.md`	Reporte técnico del procesamiento de entrevistas

C. Glosario

- **P25 / P75:** percentiles 25 y 75; delimitan el 50 % central de los precios.
- **Mediana:** valor que divide la muestra en dos mitades; resiste mejor los extremos que el promedio.
- **Deduplicación:** eliminación de anuncios repetidos o copias exactas.
- **Vistas:** número de veces que se abrió un anuncio; señal indirecta de interés.
- **Transcripción automática:** texto generado por Vosk, sin corrección manual del habla.
